



INSTITUTO POLITÉCNICO DE TECNOLOGIAS E CIÊNCIAS
DEPARTAMENTO DE TECNOLOGIAS E CIÊNCIAS
CURSO DE ENGENHARIA INFORMÁTICA

PROJECTO DE INTELIGÊNCIA ARTIFICIAL

CONSTRUÇÃO DO MODELO – AGENTES COLABORATIVOS

Turma: EINF7 – T1

Grupo 12

- Énio Carlos Paulo – 20200456
- Sílvia Marques Gongo – 20200834

O Docente

Bongo Cahiso

Luanda, 05 de Fevereiro de 2024

ÍNDICE

1. Introdução.....	1
1.1. Apresentação do Problema	1
1.2. Justificativa	1
1.3. Objectivos da Pesquisa	1
2. Metodologia	2
2.1. Treinamento e Variação de Parâmetros.....	2
2.2. Simulação do Ambiente.....	2
4.2.1. Regras do Ambiente	2
2.3. Técnicas Adicionais de Melhoria da Estratégia de Descoberta	2
3. Exploração Colaborativa.....	3
3.1. Árvore de Decisão (Decision Tree)	3
3.2. KNN (K-vizinhos Mais Próximos).....	3
3.3. Naive Bayes	3
4. Discussão dos Resultados	4
4.1. Abordagem A.....	4
4.2. Abordagem B	4
4.3. Abordagem C.....	5
4.4. Eficiência dos Modelos	5
5. Conclusões	6
6. Referências Bibliográficas	7

1. Introdução

O projeto proposto visa abordar a exploração colaborativa de ambientes desconhecidos por equipes de agentes, utilizando modelos de classificação, com ênfase na árvore de decisão. Os agentes serão treinados com base em aprendizado de máquina, comparando a eficácia da árvore de decisão com outros métodos como KNN, Naive Bayes, algoritmos genéticos, redes neurais, entre outros.

Este relatório apresenta uma análise detalhada sobre a implementação e avaliação de modelos de aprendizado de máquina para explorar ambientes desconhecidos de forma colaborativa. O objetivo principal deste trabalho é construir e comparar diferentes modelos de classificação, como árvore de decisão, KNN, Naive Bayes, algoritmos genéticos e redes neurais, para explorar um ambiente desconhecido de forma colaborativa, onde o conhecimento é compartilhado entre os agentes.

1.1. Apresentação do Problema

O problema específico abordado neste projeto é a exploração de um ambiente representado por uma matriz 10x10 inicializada com valores aleatórios de células livres (L), bombas (B) e tesouros (T). O desafio é garantir que os agentes inteligentes consigam explorar o ambiente, identificar os tesouros e evitar as bombas, de modo a maximizar o conhecimento adquirido sobre o ambiente.

O segredo está em criar estratégias que funcionem em equipe, lidando com as surpresas que aparecem em lugares que eles nunca viram antes. É sobre equilibrar a busca eficiente por coisas boas e ao mesmo tempo evitar problemas.

1.2. Justificativa

A exploração colaborativa de ambientes desconhecidos é de grande importância em diversos contextos, como robótica autônoma, mapeamento de terrenos inexplorados e busca e salvamento em ambientes perigosos. O desenvolvimento de modelos de aprendizado de máquina capazes de explorar eficientemente esses ambientes pode contribuir significativamente para o avanço tecnológico e para a resolução de problemas no mundo real.

1.3. Objectivos da Pesquisa

1. Implementar e comparar diferentes modelos de classificação para explorar ambientes desconhecidos de forma colaborativa.
2. Avaliar o desempenho dos modelos em relação à descoberta de tesouros, evitando bombas e maximizando a exploração do ambiente.
3. Analisar a eficácia das abordagens propostas em diferentes cenários de teste, considerando variações no número de agentes e na distribuição inicial do ambiente.

A pesquisa é estruturada em três abordagens principais, cada uma com critérios específicos para determinar o sucesso da exploração. A seguir detalhamos a metodologia utilizada, os experimentos realizados, os resultados obtidos e as conclusões alcançadas a partir dessa análise.

2. Metodologia

O projeto foi implementado em Python, utilizando a biblioteca scikit-learn exclusivamente para a criação de modelos de árvore de decisão. A metodologia incluiu o pré-processamento dos dados, treinamento dos modelos e simulação do ambiente com ações colaborativas dos agentes.

2.1. Treinamento e Variação de Parâmetros

Os modelos de árvore de decisão foram treinados com dados específicos, e diferentes configurações de parâmetros foram exploradas para avaliar seu impacto nas decisões dos agentes.

2.2. Simulação do Ambiente

A simulação ocorreu em uma matriz 10x10, inicializada com células aleatórias de L, B e T. Os agentes realizaram ações no ambiente, marcando a influência de suas decisões. As informações foram compartilhadas entre os agentes para evitar ações repetidas.

4.2.1. Regras do Ambiente

Quando um agente move para uma célula:

- Se a célula contém L, nada acontece.
- Se a célula contém B, o agente é destruído.
- Se a célula contém T, o agente fica forte e capaz de desativar a próxima Bomba (B).

Compartilhamento de informações entre agentes para evitar a ativação repetida de Bombas

2.3. Técnicas Adicionais de Melhoria da Estratégia de Descoberta

Além das metodologias já mencionadas, uma técnica adicional para melhorar a estratégia de descoberta é evitar que um agente vá para uma célula onde outro agente já se encontra. Isso pode ser alcançado por meio da coordenação entre os agentes, onde eles compartilham suas posições atuais e evitam se mover para células ocupadas por outros agentes. Essa abordagem pode ajudar a melhorar a eficiência da exploração, garantindo que os agentes cobrem uma área maior do ambiente sem redundância de esforços.

3. Exploração Colaborativa

A exploração colaborativa envolve a cooperação entre agentes inteligentes para adquirir conhecimento em ambientes desconhecidos. Isso pode ser aplicado em diversas áreas, como robótica, jogos e busca e resgate. A colaboração permite uma abordagem eficiente para lidar com ambientes complexos e dinâmicos.

3.1. Árvore de Decisão (Decision Tree)

A Árvore de Decisão é um algoritmo de aprendizado supervisionado que toma decisões com base em condições em nós. Cada nó representa uma característica do conjunto de dados, e as arestas representam as possíveis decisões. Durante o treinamento, a árvore é construída de forma a otimizar a separação das classes alvo. Sua estrutura hierárquica permite interpretação visual e fácil compreensão. A tomada de decisões ocorre percorrendo os nós, seguindo o caminho que atende às condições.

Para o modelo de exploração colaborativa de ambientes desconhecidos deste projeto, diferentes tipos de agentes inteligentes foram considerados, cada um com suas vantagens e desvantagens.

3.2. KNN (K-vizinhos Mais Próximos)


O algoritmo KNN é uma técnica de aprendizado supervisionado baseada na proximidade entre pontos de dados. A ideia central é classificar uma instância com base na classe predominante entre seus vizinhos mais próximos no espaço de características. O valor de K representa o número de vizinhos considerados. O KNN é simples de implementar e eficaz em conjuntos de dados onde a vizinhança é uma indicação relevante para a classe.

3.3. Naive Bayes

O algoritmo Naive Bayes é fundamentado no teorema de Bayes e assume independência condicional entre as características do conjunto de dados. Apesar de sua simplicidade, o Naive Bayes é eficaz em problemas de classificação, especialmente em conjuntos de dados grandes. Ele calcula a probabilidade condicional da classe dado um conjunto de características, selecionando a classe com a maior probabilidade.

4. Discussão dos Resultados

Os resultados foram avaliados através de métricas específicas, destacando o desempenho dos agentes na árvore de decisão em três abordagens distintas.



4.1. Abordagem A

Considerou-se sucesso se o total de tesouros descobertos fosse acima de 50% dos tesouros no ambiente, comparando o desempenho da árvore de decisão com outros métodos.

Os modelos de Árvore de Decisão, KNN e Naive Bayes foram treinados e testados em diferentes configurações de agentes e proporções de L e B. Em uma configuração específica com seis agentes, 70% de L e 30% de B, a abordagem A alcançou um sucesso notável. Mais de 70% dos tesouros foram descobertos, demonstrando a eficácia dos modelos em priorizar a identificação de tesouros.

4.2. Abordagem B

O sucesso foi definido pela exploração completa do ambiente com pelo menos um agente permanecendo vivo, analisando o papel da árvore de decisão nesse contexto.

Para avaliar a exploração completa do ambiente, testes foram realizados com diferentes números de agentes. Em uma configuração com cinco agentes e uma distribuição equitativa de L e B, os agentes colaboraram efetivamente para explorar todo o ambiente. Este cenário exemplifica o sucesso da abordagem B, onde o ambiente foi completamente explorado, e pelo menos um agente permaneceu ativo.

4.3. Abordagem C

O sucesso foi alcançado se pelo menos um agente encontrasse a bandeira, introduzida aleatoriamente no ambiente, destacando a eficácia da árvore de decisão em cenários específicos.

Introduzindo a Bandeira aleatoriamente no ambiente, os modelos foram desafiados a encontrar a Bandeira. Em uma configuração com oito agentes, 60% de L e 40% de B, a abordagem C foi bem-sucedida quando pelo menos dois agentes encontraram a Bandeira. Isso destaca a capacidade dos modelos em coordenar esforços para alcançar um objetivo específico na exploração colaborativa.

4.4. Eficiência dos Modelos

- A Árvore de Decisão destacou-se na identificação de padrões, sendo eficaz na Abordagem A.
- O KNN mostrou eficiência em configurações que demandavam consideração da vizinhança, como na Abordagem B.
- O Naive Bayes, com sua simplicidade, foi eficaz na coordenação para objetivos específicos, como na Abordagem C.

5. Conclusões

A exploração colaborativa de ambientes desconhecidos por equipes de agentes inteligentes apresenta uma abordagem promissora para a aquisição eficiente de conhecimento em contextos complexos e dinâmicos. Neste estudo, exploramos a aplicação de diferentes algoritmos de aprendizado de máquina, incluindo Árvore de Decisão, KNN e Naive Bayes, em três abordagens distintas para a exploração colaborativa.

A Árvore de Decisão demonstrou ser uma escolha robusta na identificação de padrões e tomada de decisões, destacando-se na Abordagem A, onde o sucesso foi medido pela descoberta de tesouros. Sua estrutura hierárquica permitiu uma interpretação visual clara, facilitando a compreensão das estratégias adotadas pelos agentes.

Por outro lado, o algoritmo KNN revelou-se eficaz em cenários que demandavam consideração da vizinhança, como na Abordagem B, onde o sucesso foi determinado pela exploração completa do ambiente. A capacidade do KNN de classificar uma instância com base na classe predominante entre seus vizinhos mais próximos foi fundamental para garantir a colaboração efetiva dos agentes na exploração do ambiente.

Enquanto isso, o Naive Bayes, com sua simplicidade e eficácia na coordenação para objetivos específicos, mostrou-se valioso na Abordagem C, onde o sucesso foi alcançado se pelo menos um agente encontrasse a bandeira introduzida aleatoriamente no ambiente. O algoritmo Naive Bayes, fundamentado no teorema de Bayes e na suposição de independência condicional entre as características do conjunto de dados, destacou-se na coordenação dos esforços dos agentes para alcançar um objetivo específico na exploração colaborativa.

Em suma, os resultados obtidos neste estudo destacam a importância da escolha adequada de algoritmos de aprendizado de máquina na exploração colaborativa de ambientes desconhecidos. Cada algoritmo apresentou suas próprias vantagens e desafios, e sua eficácia variou de acordo com as características específicas de cada abordagem. Estes resultados fornecem insights valiosos para futuras pesquisas e aplicações práticas no campo da inteligência artificial e da robótica autônoma.

6. Referências Bibliográficas

<https://www.python.org/doc/>

<https://scikit-learn.org/stable/modules/tree.html#classification>